

CẢI THIỆN PHÁT HIỆN NGÔN NGỮ XÚC PHẠM CHO TIẾNG VIỆT BẰNG ĐỒ THỊ TRI THỨC

Enhancing Hate Speech Span Detection for Vietnamese Using Knowledge Graph

Tên: **Trương Kim Lâm** MSSV: **250202044** Lớp: **CS2205.CH203**

VẤN ĐỀ

Ngôn ngữ xúc phạm trong tiếng Việt thường dùng **ẩn dụ** và **ám chỉ ngầm định** mang tính văn hóa xã hội đặc thù. Các mô hình ngôn ngữ thuần túy khó xử lý vì thiếu tri thức liên quan đến ngữ cảnh.

Ví dụ:

"thằng đó là thằng cờ vàng bán nước"
→ "cờ vàng" là ẩn dụ chính trị mang tính xúc phạm, nhưng PhoBERT & XLM-R đều bỏ sót.

Phân tích lỗi từ ViHOS [1]:

~24%

lỗi với **PhoBERT**
do ẩn dụ / ám chỉ ngầm định

~16%

lỗi với **XLM-R**
do ẩn dụ / ám chỉ ngầm định

Những lỗi này đến từ ngữ cảnh văn hóa mà mô hình ngôn ngữ thuần túy không thể xử lý nếu thiếu tri thức bên ngoài.

KHOẢNG TRỐNG NGHIÊN CỨU

- ViHOS [1] là công trình đầu tiên phát hiện ngôn ngữ xúc phạm ở mức span cho tiếng Việt (không phải cả câu).
- ERNIE [2] & KnowBERT [3] đã chứng minh hiệu quả khi tích hợp Knowledge Graph vào LLM ở các ngôn ngữ khác.
- Hướng này chưa được áp dụng cho hate speech detection trong tiếng Việt → đây chính là khoảng trống mà nghiên cứu này hướng đến.

MỤC TIÊU

- Xây dựng ViHSGK**
Đồ thị tri thức hate speech tiếng Việt (ViHSGK), ít nhất 300 mẫu kiểm duyệt, bao gồm từ/cụm từ và quan hệ ẩn dụ, ám chỉ ngầm định.
- Mô hình KG-GNN-Span**
Tích hợp ViHSGK vào PhoBERT qua R-GCN [4] + Cross-Attention + CRF decoder [5]. Mục tiêu F1 > 0.7770 trên ViHOS.
- Kiểm chứng ViHSGK**
So sánh với một phiên bản khác sử dụng đồ thị ngẫu nhiên, từ đó xác nhận được cải thiện đến từ ViHSGK chứ không phải từ một cấu trúc đồ thị đơn thuần.

PHƯƠNG PHÁP


① Xây dựng ViHSGK

- Dùng LLM trích xuất cụm từ & quan hệ từ training data ViHOS, tập trung vào các trường hợp lỗi.
- Kiểm duyệt thủ công bởi người Việt. Mục tiêu ≥ 300 mẫu.

Ví dụ quan hệ:

"cờ vàng" → [is_metaphor_for] → "phe đối lập"
"cờ vàng" → [domain] → "chính trị"
"lũ súc vật" → [is_type] → "offensive_pronoun"

② Kiến trúc mô hình KG-GNN-Span Detection



③ Đánh giá

- Train/test trên ViHOS benchmark, so sánh F1 với PhoBERT & XLM-R.
- So sánh ViHSGK với một đồ thị ngẫu nhiên khác cùng kích thước để xác nhận cải thiện đến từ tri thức trong ViHSGK.

KẾT QUẢ MONG ĐỢI

F1 Score trên ViHOS benchmark:

PhoBERT [1]	0.7716
XLM-R [1]	0.7770
Đề xuất ▶	> 0.7770

- ViHSGK với ít nhất 300 mẫu, công bố như một open-source cho NLP tiếng Việt.
- Đạt cải thiện rõ rệt trên nhóm lỗi ẩn dụ & ám chỉ ngầm định.
- Xác nhận cải thiện: ViHSGK vượt trội hơn một đồ thị ngẫu nhiên khác cùng kích thước.
- Trở thành nền tảng cho kiểm duyệt nội dung tự động trong tiếng Việt.

TÀI LIỆU THAM KHẢO

- [1] Hoang et al. *ViHOS: Hate Speech Spans Detection for Vietnamese*. EACL 2023. [2] Zhang et al. *ERNIE: Enhanced Language Representation with Informative Entities*. ACL 2019. [3] Peters et al. *Knowledge Enhanced Contextual Word Representations*. EMNLP 2019. [4] Schlichtkrull et al. *Modeling Relational Data with Graph Convolutional Networks*. ESWC 2018. [5] Lafferty et al. *Conditional Random Fields*. ICML 2001.