

THÔNG TIN CHUNG CỦA NHÓM

- Link YouTube video của báo cáo (tối đa 5 phút):
TBU
- Link slides (dạng .pdf đặt trên Github của nhóm):
<https://github.com/ltk84/CS2205.CH203/blob/master/SLIDES%20-%20ENHANCING%20HATE%20SPEECH%20SPAN%20DETECTION%20FOR%20VIETNAMESE%20USING%20KNOWLEDGE%20GRAPH.pdf>
- *Mỗi thành viên của nhóm điền thông tin vào một dòng theo mẫu bên dưới*
- *Sau đó điền vào Đề cương nghiên cứu (tối đa 5 trang), rồi chọn Turn in*
- *Lớp Cao học, mỗi nhóm một thành viên*

- Họ và Tên: Trương Kim
Lâm
- MSSV: 250202044



- Lớp: CS2205.CH203
- Tự đánh giá (điểm tổng kết môn): 9/10
- Số buổi vắng: 1
- Số câu hỏi QT cá nhân: 2
- Số câu hỏi QT của cả nhóm: 2
- Link Github:
<https://github.com/ltk84/CS2205.CH203>

ĐỀ CƯƠNG NGHIÊN CỨU

TÊN ĐỀ TÀI (IN HOA)

CẢI THIỆN PHÁT HIỆN NGÔN NGỮ XÚC PHẠM CHO TIẾNG VIỆT BẰNG ĐỒ THỊ TRI THỨC

TÊN ĐỀ TÀI TIẾNG ANH (IN HOA)

ENHANCING HATE SPEECH SPAN DETECTION FOR VIETNAMESE USING KNOWLEDGE GRAPH

TÓM TẮT *(Tối đa 400 từ)*

Phát hiện ngôn ngữ xúc phạm là một bài toán khá phổ biến trong xử lý ngôn ngữ tự nhiên, tuy nhiên đối với tiếng Việt với các câu từ thường xuyên sử dụng ẩn dụ, hoán dụ, ám chỉ ngầm định hay các ngữ cảnh văn hoá xã hội đặc thù thì việc phát hiện ngôn ngữ xúc phạm vẫn còn khá hạn chế.

Công trình đầu tiên cho bài toán này là ViHOS [1], thay vì chỉ phân loại toàn bộ câu là có xúc phạm hay không thì công trình này xác định từng khoảng văn bản cụ thể trong câu đó mà nó có mang tính xúc phạm. Một số mô hình ngôn ngữ như PhoBERT và XLM-R dù đạt kết quả tốt trên ViHOS nhưng vẫn còn một phần lỗi đáng kể đến từ việc thiếu tri thức bên ngoài để có thể hiểu các biểu đạt mang tính ẩn dụ hay liên quan đến ngữ cảnh chính trị, văn hoá nhất định.

Nghiên cứu trong đề cương này đề xuất một kiến trúc mới lấy cảm hứng từ các công trình tích hợp đồ thị tri thức vào mô hình ngôn ngữ trước đó như là ERNIE [2] hay KnowBERT [3] đã được chứng minh hiệu quả trong các ngôn ngữ khác. Kết quả kỳ vọng là cải thiện F1 score vượt qua baseline PhoBERT (0.7716) và XLM-R (0.7770) theo benchmark của ViHOS [1], đặc biệt trên các nhóm lỗi liên quan đến ẩn dụ và ám chỉ ngầm định, đồng thời đóng góp được đồ thị tri thức tiếng Việt liên quan đến ngôn ngữ xúc phạm như một tài nguyên độc lập cho lĩnh vực xử lý ngôn ngữ tự nhiên trong tiếng Việt.

GIỚI THIỆU (Tối đa 1 trang A4)

Ngôn ngữ xúc phạm trên mạng xã hội là một vấn đề phổ biến và khó kiểm soát, đặc biệt là đối với tiếng Việt vì câu từ thường xuyên sử dụng ẩn dụ, hoán dụ hay ám chỉ ngầm định mang tính văn hoá xã hội đặc thù. Phần lớn là các nghiên cứu hiện có tiếp cận bài toán này ở mức phân loại toàn bộ câu, tức là chỉ xác định cả câu đó có xúc phạm hay không. Tuy nhiên cách tiếp cận này thiếu độ chi tiết cần thiết cho các ứng dụng thực tế, vì một bình luận có thể chỉ chứa một vài từ xúc phạm và xen lẫn trong đó là các nội dung trung lập.

ViHOS [1] là công trình đầu tiên cho bài toán hate speech span detection trong tiếng Việt, xác định từng khoảng văn bản cụ thể mang tính xúc phạm trong câu thay vì chỉ phân loại toàn bộ câu. Dù PhoBERT và XLM-R đạt kết quả tốt trên benchmark của ViHOS (F1 score lần lượt là 0.7716 và 0.7770), error analysis trong bài này cũng chỉ ra rằng vẫn còn một phần đáng kể lỗi (khoảng 24% lỗi đối với PhoBERT và 16% đối XLM-R) đến từ các trường hợp ẩn dụ, hoán dụ và ám chỉ ngầm định mang tính văn hoá chính trị xã hội. Ví dụ như từ “cờ vàng” mang ẩn dụ chính trị xúc phạm trong ngữ cảnh Việt Nam, nhưng cả hai mô hình đều không nhận ra được điều đó.

Đây là những trường hợp mà các mô hình ngôn ngữ thuần túy khó xử lý vì chúng không được học các ngữ cảnh trong văn bản. Trong khi đó, các công trình như ERNIE [2] hay KnowBERT [3] đã chứng minh rằng việc tích hợp đồ thị tri thức bên ngoài vào mô hình ngôn ngữ có thể cải thiện đáng kể khả năng hiểu ngữ nghĩa. Dù vậy, hướng tiếp cận này chưa được áp dụng trong bài toán phát hiện ngôn ngữ xúc phạm trong tiếng Việt, đây chính là khoảng trống mà nghiên cứu này hướng đến.

Nghiên cứu này đề xuất tích hợp đồ thị tri thức tiếng Việt vào mô hình phát hiện ngôn ngữ xúc phạm, kết hợp cùng PhoBERT encoder và CRF decoder [5]. Đầu vào là một câu bình luận tiếng Việt, ví dụ như là “thằng đó là thằng cờ vàng bán nước” và đầu ra là các đoạn văn bản mà được xác định là xúc phạm có trong câu bình luận đó, ví dụ như là “thằng”, “cờ vàng”, “bán nước”. Từ đó, nghiên cứu này kỳ vọng có thể cải thiện khả năng phát hiện các khoảng văn bản xúc phạm mang tính ẩn dụ và ám chỉ ngầm định trong tiếng Việt.

MỤC TIÊU *(Viết trong vòng 3 mục tiêu)*

Nghiên cứu này hướng đến ba mục tiêu chính:

1. Xây dựng đồ thị tri thức ngôn ngữ xúc phạm tiếng Việt (tạm gọi là ViHSKG - Vietnamese Hate Speech Knowledge Graph) với ít nhất 300 mẫu được kiểm duyệt bởi người Việt, bao gồm các từ, cụm từ, khái niệm và mối quan hệ liên quan đến ngôn ngữ xúc phạm mang tính ẩn dụ và ám chỉ trong ngữ cảnh văn hóa xã hội Việt Nam.
2. Xây dựng và huấn luyện mô hình với kiến trúc Knowledge Graph - Graph Neural Network - Span Detection, tích hợp ViHSKG vào PhoBERT thông qua R-GCN [4] và Cross-Attention, từ đó có thể đạt F1 score vượt baseline PhoBERT (0.7716) và XLM-R (0.7770) trên benchmark ViHOS [1].
3. Kiểm chứng tính hiệu quả của đồ thị tri thức bằng cách so sánh mô hình đề xuất với một phiên bản khác sử dụng đồ thị tri thức ngẫu nhiên. Mục đích là để xác nhận rằng cải thiện đạt được trong nghiên cứu này đến từ ViHSKG chứ không phải từ một cấu trúc đồ thị đơn thuần.

NỘI DUNG VÀ PHƯƠNG PHÁP


Để đạt được mục tiêu thứ nhất, đồ thị tri thức ViHSKG được xây dựng theo quy trình bao gồm hai bước.

1. Sử dụng LLM để trích xuất các cụm từ và mối quan hệ từ training data của ViHOS [1], tập trung vào các trường hợp lỗi được chỉ ra trong error analysis của paper gốc. Ví dụ, từ câu “đám cờ vàng là lũ súc vật lưu vong”, kỳ vọng sẽ trích xuất được các quan hệ như sau:

"cờ vàng" => [is_metaphor_for] => "phe đối lập chính trị"
"cờ vàng" => [offensive_to] => "người Việt Nam"
"cờ vàng" => [domain] => "chính trị"
"lũ súc vật" => [is_type] => "offensive_pronoun"

2. Kết quả của việc trích xuất các cụm từ và các mối quan hệ ở bước đầu sẽ được kiểm duyệt và bổ sung thủ công. Mục tiêu là xây dựng và kiểm duyệt ít nhất 300 mẫu như vậy.

Tiếp theo, để đạt được mục tiêu thứ hai, mô hình được xây dựng dựa trên kiến trúc mới như sau:



Nhánh thứ nhất (A) dùng PhoBERT encoder để mã hóa văn bản đầu vào. Nhánh thứ hai (B) dùng R-GCN [4] (một loại mạng neural để xử lý đồ thị có khả năng học mối quan hệ giữa các khái niệm, ví dụ như trong ví dụ này là "cờ vàng => chính trị => xúc phạm") để mã hóa ViHSGK, từ đó học được mối quan hệ giữa các cụm từ trong đồ thị. Hai nhánh này được kết nối thông qua Cross-Attention, cho phép mô hình tra cứu thông tin từ đồ thị khi đang đọc từng từ trong câu. Đầu ra từ Cross-Attention sẽ đi qua CRF decoder [5] để đảm bảo các nhãn đầu ra cuối cùng nhất quán và hợp lệ theo chuỗi. Bước kế tiếp sẽ tiến hành huấn luyện mô hình này trên training set của ViHOS, sau đó sẽ đánh giá trên test set của ViHOS, sau đó so sánh trực tiếp kết quả F1 score với baseline PhoBERT và XLM-R đã được đề cập trong paper gốc.

Cuối cùng, để đạt được mục tiêu thứ ba, mô hình đề xuất sẽ được so sánh với một phiên bản khác có cùng kiến trúc nhưng thay đồ thị tri thức ViHSGK bằng một đồ thị ngẫu nhiên có cùng số lượng mẫu. Nếu mô hình dùng ViHSGK cho kết quả tốt hơn đáng kể so với phiên bản dùng đồ thị ngẫu nhiên thì sẽ xác nhận được rằng có sự cải thiện đến từ tri thức trong ViHSGK.

KẾT QUẢ MONG ĐỢI

Nghiên cứu này kỳ vọng sẽ đạt được ba kết quả chính tương ứng với ba mục tiêu đã đề ra.

Thứ nhất là xây dựng được một đồ thị tri thức liên quan đến ngôn ngữ xúc phạm trong tiếng Việt hoàn chỉnh với ít nhất 300 mẫu đã được kiểm duyệt. Kỳ vọng sẽ công bố công khai như một open source cho lĩnh vực NLP tiếng Việt, có thể tái sử dụng cho các nghiên cứu liên quan.

Thứ hai là xây dựng và đánh giá được một mô hình phát hiện ngôn ngữ xúc phạm trong tiếng Việt có khả năng xác định từng khoảng văn bản xúc phạm trong câu, đạt F1 score vượt baseline PhoBERT (0.7716) và XLM-R (0.7770) theo benchmark của ViHOS, đặc biệt là trên các nhóm lỗi liên quan đến ẩn dụ và ám chỉ ngầm định.

Thứ ba là chứng minh được cải thiện đạt được đến từ tri thức được mã hoá trong ViHSKG thông qua kết quả so sánh với một mô hình dùng đồ thị ngẫu nhiên khác.

Ngoài ra, về mặt ứng dụng, nghiên cứu này kỳ vọng có thể trở thành nền tảng cho các hệ thống kiểm duyệt nội dung tự động trên các mạng xã hội, nhóm chat trực tuyến hay diễn đàn tiếng Việt, giúp phát hiện chính xác hơn các nội dung xúc phạm mang tính ẩn dụ mà các hệ thống hiện tại có thể bỏ sót.

TÀI LIỆU THAM KHẢO (*Định dạng DBLP*)

- [1]. Phu Gia Hoang, Canh Duc Luu, Khanh Quoc Tran, Kiet Van Nguyen, Ngan Luu-Thuy Nguyen: ViHOS: Hate Speech Spans Detection for Vietnamese. EACL 2023: 652-669. <https://aclanthology.org/2023.eacl-main.47>
- [2]. Zhengyan Zhang, Xu Han, Zhiyuan Liu, Xin Jiang, Maosong Sun, Qun Liu: ERNIE: Enhanced Language Representation with Informative Entities. ACL 2019: 1441-1451. <https://aclanthology.org/P19-1139>
- [3]. Matthew E. Peters, Mark Neumann, Robert L. Logan IV, Roy Schwartz, Vidur Jain, Sam Bamman, Noah A. Smith: Knowledge Enhanced Contextual Word Representations. EMNLP 2019: 2880-2896. <https://aclanthology.org/D19-1005>
- [4]. Michael Schlichtkrull, Thomas N. Kipf, Peter Bloem, Rianne van den Berg, Ivan Titov, Max Welling: Modeling Relational Data with Graph Convolutional Networks. ESWC 2018: 593-607. <https://arxiv.org/abs/1703.06103>
- [5]. John D. Lafferty, Andrew McCallum, Fernando C. N. Pereira: Conditional Random Fields: Probabilistic Models for Segmenting and Labeling Sequence Data. ICML 2001: 282-289. <https://www.cs.columbia.edu/~jebara/6772/papers/crf.pdf>