

CẢI THIỆN PHÁT HIỆN NGÔN NGỮ XÚC PHẠM CHO TIẾNG VIỆT BẰNG ĐỒ THỊ TRI THỨC

ENHANCING HATE SPEECH SPAN DETECTION FOR VIETNAMESE USING
KNOWLEDGE GRAPH

Trương Kim Lâm – 250202044



Tóm tắt

- **Lớp:** CS2205.CH203
- **Link Github của nhóm:** <https://github.com/ltk84/CS2205.CH203>
- **Link YouTube video:** <https://youtu.be/tPBxJideCFw>
- **Tên thành viên:** Trương Kim Lâm

Tóm tắt

01

BÀI TOÁN

Phát hiện từng *khoảng văn bản xúc phạm* trong tiếng Việt (*tham khảo ViHOS EACL 2023 [1]*).

02

VẤN ĐỀ

PhoBERT & XLM-R vẫn **lỗi ~16–24%** ở các câu ẩn dụ hay ám chỉ ngầm định.

03

ĐỀ XUẤT

Tích hợp đồ thị tri thức tiếng Việt vào PhoBERT qua *R-GCN [4]* + *Cross-Attention + CRF [5]*.

04

KỶ VỌNG

F1 > 0.7770, đạt cải thiện rõ rệt trên nhóm lỗi ẩn dụ và ám chỉ ngầm định.

Giới thiệu

- **Ngữ cảnh:** Ngôn ngữ xúc phạm tiếng Việt trên MXH thường dùng ẩn dụ, hoán dụ, ám chỉ ngầm định mang tính văn hóa xã hội đặc thù, rất khó phát hiện tự động.
- **ViHOS [\[1\]](#):** Công trình đầu tiên cho bài toán Hate Speech Span Detection tiếng Việt, thay vì phân loại cả câu, bài toán này xác định từng đoạn văn bản trong câu.

PhoBERT

F1 = 0.7716

~24% lỗi ẩn dụ

XLM-R

F1 = 0.7770

~16% lỗi ẩn dụ

Ví dụ lỗi điển hình

"cờ vàng": ẩn dụ chính trị xúc phạm trong ngữ cảnh VN mà cả hai mô hình đều không nhận ra

Giới thiệu

- **Khoảng trống:** Các mô hình ngôn ngữ thuần túy khó xử lý ẩn dụ và ám chỉ văn hóa chính trị vì thiếu tri thức bên ngoài về ngữ cảnh đặc thù tiếng Việt.
- **Hướng giải quyết:** ERNIE ACL 2019 [\[2\]](#) và KnowBERT EMNLP 2019 [\[3\]](#) chứng minh tích hợp Knowledge Graph có thể cải thiện ngữ nghĩa, tuy nhiên nó chưa áp dụng cho bài toán tiếng Việt.
- **Đề xuất:** Xây dựng Vietnamese Hate Speech Knowledge Graph (ViHSKG) và tích hợp vào PhoBERT encoder qua R-GCN + Cross-Attention + CRF decoder.

01

Xây dựng ViHSGK

Đồ thị tri thức ngôn ngữ
xúc phạm trong tiếng Việt
với ít nhất 300 mẫu được
kiểm duyệt, bao gồm từ,
cụm từ, mối quan hệ liên
quan.

02

Mô hình KG-GNN-Span

Tích hợp ViHSGK vào
PhoBERT thông qua R-GCN
+ Cross-Attention + CRF, từ
đó đạt **F1 > 0.7770** trên
benchmark ViHOS.


03

Kiểm chứng ViHSGK

So sánh mô hình đề xuất
với một phiên bản khác sử
dụng đồ thị ngẫu nhiên, từ
đó xác nhận được cải thiện
đến từ ViHSGK chứ không
phải từ một cấu trúc đồ thị
đơn thuần.

Nội dung và Phương pháp

BƯỚC 1: XÂY DỰNG VIHOSKG



Ví dụ: “đám cờ vàng là lũ súc vật lưu vong”


“cờ vàng” → [is_metaphor_for] → “phe đối lập chính trị”

“cờ vàng” → [offensive_to] → “người Việt Nam”


“lũ súc vật” → [is_type] → “offensive_pronoun”

Nội dung và Phương pháp

BƯỚC 2: KIẾN TRÚC KG-GNN-SPAN



BƯỚC 3: KIỂM CHỨNG



Kết quả dự kiến

KẾT QUẢ 1

ViHSG Open-source

Đồ thị tri thức với ít nhất 300 mẫu kiểm duyệt, công bố như một mã nguồn mở cho lĩnh vực NLP tiếng Việt, có thể tái sử dụng cho các nghiên cứu liên quan.

KẾT QUẢ 2

F1 vượt Baseline

Mô hình đề xuất đạt $F1 > \text{PhoBERT (0.7716)} \ \& \ \text{XLM-R (0.7770)}$ trên benchmark từ ViHOS, đặc biệt trên nhóm lỗi ẩn dụ và ám chỉ ngầm định.

KẾT QUẢ 3

Xác nhận cải thiện

Mô hình đề xuất với ViHSG cho kết quả tốt hơn phiên bản dùng đồ thị ngẫu nhiên, từ đó xác nhận được hiệu quả đến từ tri thức trong ViHSG, không phải cấu trúc đồ thị đơn thuần.

Tài liệu tham khảo

- [1]. Phu Gia Hoang, Canh Duc Luu, Khanh Quoc Tran, Kiet Van Nguyen, Ngan Luu-Thuy Nguyen: ViHOS: Hate Speech Spans Detection for Vietnamese. EACL 2023: 652-669. <https://aclanthology.org/2023.eacl-main.47>
- [2]. Zhengyan Zhang, Xu Han, Zhiyuan Liu, Xin Jiang, Maosong Sun, Qun Liu: ERNIE: Enhanced Language Representation with Informative Entities. ACL 2019: 1441-1451. <https://aclanthology.org/P19-1139>
- [3]. Matthew E. Peters, Mark Neumann, Robert L. Logan IV, Roy Schwartz, Vidur Jain, Sam Bamman, Noah A. Smith: Knowledge Enhanced Contextual Word Representations. EMNLP 2019: 2880-2896.
<https://aclanthology.org/D19-1005>
- [4]. Michael Schlichtkrull, Thomas N. Kipf, Peter Bloem, Rianne van den Berg, Ivan Titov, Max Welling: Modeling Relational Data with Graph Convolutional Networks. ESWC 2018: 593-607. <https://arxiv.org/abs/1703.06103>
- [5]. John D. Lafferty, Andrew McCallum, Fernando C. N. Pereira: Conditional Random Fields: Probabilistic Models for Segmenting and Labeling Sequence Data. ICML 2001: 282-289.
<https://www.cs.columbia.edu/~jebara/6772/papers/crf.pdf>